

День 4 • 🔍 Введение в RAG и работу с векторными БД

📋 Обсуждаемые темы:

- 🤔 Что такое RAG (Retrieval-Augmented Generation)? (5 минут)
- 🎯 Зачем нужен RAG? (10 минут)
- 🔄 Последовательность работы RAG (10 минут)
- 📊 Что такое векторная БД? (5 минут)
- 💡 Зачем нужна векторная БД? (10 минут)

🤔 Что такое RAG (Retrieval-Augmented Generation)?

RAG — это подход, сочетающий генеративные модели (например, LLM) и извлечение информации из внешней базы данных.

Он используется для создания ответов, которые не просто «угадываются» моделью, а основаны на достоверных данных.

🤔 Что такое RAG: ключевая идея

AI не «знает всё».

Он обращается к внешнему хранилищу знаний — чаще всего к векторной базе данных — и достаёт оттуда релевантные фрагменты, прежде чем сгенерировать ответ.

-  **Повышение точности:** Модель опирается на проверенные данные
-  **Актуальность:** Можно добавлять новые данные без переобучения модели
-  **Контроль:** Ответы становятся объяснимыми и воспроизводимыми
-  **Гибкость:** Легко обновлять знания без изменения модели


Пример:

Вместо того чтобы надеяться, что `LLM` помнит последние обновления документации, мы сами предоставляем ей нужные тексты через `RAG`.

Последовательность работы RAG: этапы

1.  Пользователь делает запрос к **AI**
2.  Модель преобразует запрос в **эмбединг** — числовое представление запроса
3.  Происходит поиск по **векторной базе** — находятся наиболее близкие по смыслу документы
4.  **RAG** передаёт найденный контекст в **LLM**, и только потом генерируется финальный ответ

Последовательность работы RAG: схема





Что такое векторная БД?

Векторная база данных — специализированная система хранения и поиска данных, представленных в виде векторов (то есть многомерных чисел), которая позволяет находить похожие по смыслу объекты, а не только точные совпадения.



Отличие векторной и реляционной БД

- 📌 Обычные базы данных ищут точные значения — например, слово "кот" не найдёт "кошка"
- 🔍 Векторные базы — наоборот, ищут по смысловой близости
- 🎯 Это критично для задач, где важна семантика, а не синтаксис: поиск, рекомендательные системы, чат-боты, RAG

Что можно хранить в векторной БД?

-  Текстовые фрагменты (чанки документов)
-  Изображения
-  Аудио
-  Пользовательские профили
-  Продукты и товары (для рекомендаций)

Вы сохранили в базу текст:

«Чтобы авторизоваться, используйте токен API».

А пользователь ищет:

«Как подключиться к API?»

В обычной БД — 0 совпадений


В векторной БД — найден семантически близкий текст

Как сделать векторную БД: этапы

1.  **Сбор и разбиение данных:** текст делится на чанки — небольшие фрагменты по 300–500 слов
2.  **Эмбеddинг:** каждый чанк переводится в вектор с помощью модели (например, `text-embedding-3-small`, `GigaChat Embeddings`)
3.  **Сохранение:** векторы сохраняются в специализированную базу — `FAISS` , `Qdrant` , `ChromaDB` , `pgvector` , `Pinecone`



Работа RAG: схема извлечения при запросе



-  **Hybrid Search** — комбинация векторного и keyword-поиска (BM25 + vectors) для лучшей точности
-  **GraphRAG** — поиск по графу знаний вместо плоской векторной базы (реализация Microsoft)
-  **Agentic RAG** — агент сам решает, когда и что искать, может делать несколько запросов
-  **Local RAG** — полностью локальный стек: `Ollama` + `ChromaDB` без внешних API

-  RAG — это мост между генерацией и достоверными фактами
-  Векторные БД — основа этого подхода
-  Векторная БД не заменяет SQL или NoSQL, а дополняет там, где важна семантика
-  Направление активно развивается: GraphRAG, Agentic RAG, Hybrid Search
-  Освоение RAG — шаг к созданию умных AI-решений, которые обучаются данными, а не кодом

Вы получили новые инструменты — но опыт начинается с практики... 

 **Исследуйте** — пробуйте код, экспериментируйте, ошибайтесь

 **Углубляйтесь** — каждая тема открывает новые возможности

 **Создавайте** — даже маленький проект лучше теории

Это невозможно, пока вы это не сделаете!

Успехов!